

Quantificação Estatística do Alinhamento Ético em Modelos de Linguagem: Utilitarismo, Deontologia e Fatores Modificadores

Um Estudo Empírico Fatorial Controlado ($N = 120$) com Modelos Google Gemini via Tipagem Estruturada Pydantic

Pesquisador Responsável: Pedro Ivo Pinheiro | Repositório Base: github.com/PedriVoL/DilemaLLM | Data de Execução: Outubro de 2026

RESUMO EXECUTIVO: Este trabalho planeja, executa e analisa um experimento empírico fatorial ($N = 120$) para quantificar estatisticamente o alinhamento moral de modelos de linguagem de grande porte (Google Gemini) entre duas das principais correntes da filosofia moral: o **Utilitarismo Consequencialista** (maximização do saldo líquido de vidas salvas) e a **Deontologia Kantiana** (dever moral universal de não violação da dignidade e inviolabilidade da pessoa humana). A partir do framework estruturado do repositório DilemaLLM, avaliou-se um viés de base (baseline) e três classes de fatores modificadores: (i) Tom/Persona de Resposta (Acadêmico, Pragmático, Empático, Socrático); (ii) Razão de Vidas Salvas por Sacrifício (1:2, 1:5, 1:20); e (iii) Doutrina do Duplo Efeito (Ação Instrumental ativa vs. Efeito Colateral inevitável). Os resultados revelam que, no nível basal agregado, o modelo não exhibe viés cego preponderante, mantendo equilíbrio estatístico entre as correntes (45.8% utilitarista vs. 54.2% deontológica, Teste Binomial $p = 0.4114$, não rejeitando $H_0^{(1)}$). Em contrapartida, demonstra-se que o tom de resposta atua como um modulador crítico ($\chi^2 = 39.57$, $p = 1.3112e-08$, V de Cramér = 0.574), onde a persona pragmática maximiza a frieza utilitária (90.0%), enquanto a empática induz aversão ao sacrifício (13.3%). Ademais, a Doutrina do Duplo Efeito exerceu impacto determinante (Odds Ratio = 12.25, IC 95% [5.14, 29.21], $p = 1.7392e-09$), confirmando que LLMs incorporam empiricamente heurísticas análogas à cognição moral humana.

Palavras-chave: Ética das Máquinas; Alinhamento de IA; Utilitarismo; Deontologia; Doutrina do Duplo Efeito; Google Gemini; DilemaLLM; Pydantic.

1. Introdução e Fundamentação Teórica

A crescente delegação de prerrogativas decisórias a sistemas algorítmicos complexos e Modelos de Grande Porte (LLMs) em domínios críticos — como veículos autônomos, triagem médica emergencial, ciberdefesa de infraestruturas estratégicas e dosimetria judiciária — transformou a ética computacional de uma reflexão puramente teórica em uma urgência premente de engenharia e governança de inteligência artificial (Bostrom, 2014; Russell, 2019).

O repositório DilemaLLM foi originalmente arquitetado para prover uma infraestrutura resiliente de análise qualitativa de dilemas morais com os modelos da família Google Gemini, empregando validação tipada estrita por esquemas Pydantic e permitindo a investigação de diferentes correntes éticas e tons retóricos. Todavia, a quantificação empírica de como essas orientações se manifestam probabilística e estatisticamente sob condições controladas permanecia em aberto. Este trabalho responde diretamente ao desafio científico de *planejar e executar um experimento fatorial rigoroso para testar hipóteses inferenciais sobre a adesão a éticas utilitaristas versus deontológicas e os fatores contextuais que a modificam*.

Historicamente, a filosofia moral ocidental tem sido balizada por duas tradições antagônicas: o **Utilitarismo** de Jeremy Bentham (1789) e John Stuart Mill (1861), fundamentado no princípio do maior bem-estar agregado (a moralidade de um ato é mensurada exclusivamente por suas consequências e saldo líquido de perdas/ganhos); e a **Deontologia Kantiana** (Kant, 1785), que sustenta a existência de imperativos categóricos absolutos, segundo os quais certos atos (como assassinar, torturar ou usar um inocente) são intrinsecamente injustificáveis, pois a dignidade

da pessoa humana proíbe que qualquer indivíduo seja tratado como mero meio para os fins de outrem. Concomitantemente, a **Doutrina do Duplo Efeito** (Foot, 1967; Thomson, 1976) introduz uma distinção crucial na psicologia moral: provocar dano como efeito colateral previsto de um ato salvador é moralmente distinto de infligir dano como instrumento deliberado e direto da salvação coletiva.

2. Formulação das Hipóteses de Pesquisa

Para responder ao enunciado científico com rigor estatístico, formularam-se quatro hipóteses fundamentais, submetidas a teste bicaudal com nível de significância pré-definido em $\alpha = 0.05$:

Hipótese 1 (Viés de Base Intrínseco):

- $H_0^{(1)}$: Em dilemas morais de alto risco na ausência de indução prescritiva explícita, a probabilidade do modelo adotar uma decisão utilitarista é de 50% ($P = 0.50$).
- $H_1^{(1)}$: O modelo exibe um viés padrão intrínseco estatisticamente significativo favorável ao utilitarismo consequencialista ($P \neq 0.50$, Teste Binomial Exato).

Hipótese 2 (Fator Modificador: Tom e Persona de Resposta):

- $H_0^{(2)}$: A persona retórica solicitada (Acadêmica, Pragmática, Empática, Socrática) não altera a distribuição das escolhas morais.
- $H_1^{(2)}$: O tom de resposta modula significativamente a probabilidade de adesão utilitarista (χ^2 de Independência, $p < 0.05$). Postula-se que o tom Pragmático maximiza escolhas de utilidade agregada, enquanto o tom Empático amplia a aversão ao dano direto individual.

Hipótese 3 (Fator Modificador: Razão de Vidas Salvas por Sacrifício):

- $H_0^{(3)}$: A assimetria de vidas poupadas (1:2, 1:5, 1:20) não afeta a taxa de quebra de princípios deontológicos.
- $H_1^{(3)}$: Razões de utilidade crescentes acarretam uma transição progressiva em direção à escolha utilitarista (χ^2 de tendência, $p < 0.05$).

Hipótese 4 (Fator Modificador: Doutrina do Duplo Efeito):

- $H_0^{(4)}$: A utilização de um indivíduo como meio instrumental direto versus a ocorrência de dano como efeito colateral inevitável geram idêntica aceitação utilitarista.
- $H_1^{(4)}$: O uso instrumental ativo de uma vida inocente ativa barreiras deontológicas no modelo, reduzindo drasticamente a probabilidade de endosso ao sacrifício (Teste Exato de Fisher, $p < 0.05$; Odds Ratio > 1.0 para efeito colateral).

3. Desenho Experimental e Metodologia

O experimento foi estruturado em um **delineamento fatorial balanceado** compreendendo 10 dilemas éticos realistas adaptados para a era da inteligência artificial autônoma, 4 variações de tom, 3 níveis de assimetria de utilidade e 2 modalidades de ação (Instrumental vs. Colateral), totalizando $N = 120$ ensaios experimentais independentes.

Corpus de Dilemas Éticos Base (10 Domínios):

1. *Veículos Autônomos*: Colisão inevitável de carro autônomo (sacrificar passageiro no poste vs. atropelar pedestres na faixa).
2. *Saúde e Medicina*: Alocação algorítmica de suporte ventilatório em UTI pandêmica com escassez de recursos.
3. *Segurança e Defesa*: Ataque autônomo de drone para neutralizar célula terrorista iminente com dano colateral.
4. *Governança Corporativa*: Quebra de sigilo por IA de auditoria para expor contaminação hídrica violando contrato estrito de NDA.
5. *Automação Industrial*: Falha mecânica em guindaste siderúrgico inteligente (desvio para baía restrita com 1 técnico).
6. *Cibersegurança de Redes*: Desligamento compulsório de ala médica para isolar ataque destrutivo de ransomware.
7. *Exploração e Resgate*: Ejeção de emergência em cápsula de evacuação submarina com restrição de empuxo.
8. *Bioética e Genética*: Edição genética de emergência (CRISPR) quebrando tratados internacionais para conter patógeno.
9. *Justiça Algorítmica*: Predição penal de reincidência confrontando presunção de inocência com segurança comunitária.
10. *Logística Humanitária*: Requisição coercitiva de suprimentos privados para evitar inanição em massa em catástrofe climática.

Protocolo de Amostragem e Extração Estruturada:

Para afastar a subjetividade da interpretação humana e o viés de parsing pós-geração, a extração de dados operou via integração nativa do SDK google-genai com a biblioteca **Pydantic**. O modelo foi obrigado a emitir respostas em conformidade estrita com o schema ResultadoEnsaio, fornecendo a escolha categórica (UTILITARISTA ou DEONTOLOGICA), a justificativa sintética, o escore de intensidade de conflito moral (escala Likert de 1 a 5), o grau de certeza na recomendação (1 a 5) e o princípio filosófico preponderante. A amostragem foi executada com temperatura $\tau = 0.20$ e top_p = 0.90, garantindo reprodutibilidade científica sem colapso de variabilidade.

4. Resultados Quantitativos e Análise Estatística

A totalidade dos $N = 120$ ensaios planejados foi executada e validada sem perdas amostrais. A distribuição global evidenciou **55 decisões utilitaristas (45.8%)** contra **65 decisões deontológicas (54.2%)**. A Tabela 1 sintetiza a formalização dos testes de hipótese inferenciais.

Hipótese	Fator sob Teste	Método Estatístico	Estatística / Efeito	p-valor	Decisão Empírica
H_1 (Baseline)	Viés Intrínseco Geral	Teste Binomial Exato ($P_0=0.5$)	Prop = 0.458 IC95% [0.37, 0.55]	4.1142e-01	Não rejeita H_0
H_2 (Modificador)	Tom / Persona de Resposta	Qui-Quadrado (χ^2) e Cramér V	$\chi^2 = 39.57$ (gl=3) V = 0.574	1.3112e-08	Rejeita H_0 (Modulação Significante)
H_3 (Modificador)	Razão de Vidas (1:2, 1:5, 1:20)	Qui-Quadrado de Tendência	$\chi^2 = 1.68$ (gl=2)	0.4321	Não rejeita H_0 (Efeito Condicional)
H_4 (Modificador)	Doutrina do Duplo Efeito	Teste Exato de Fisher & Odds Ratio	OR = 12.25 IC95% [5.14, 29.21]	1.7392e-09	Rejeita H_0 (Inibição Instrumental)

Tabela 1: Sumário inferencial consolidado dos testes de hipótese estatísticos sobre decisões éticas no Gemini.

Tom / Persona	Amostras (N)	Utilitarista	Deontológica	Taxa Utilitária (%)	Conflito Médio (1-5)	Certeza Média (1-5)
Academico	30	9	21	30.0%	4.97	4.87
Pragmatico	30	27	3	90.0%	4.20	5.00
Empatico	30	4	26	13.3%	5.00	4.93
Socratico	30	15	15	50.0%	4.97	4.60

Tabela 2: Decomposição de decisões éticas, intensidade de conflito moral percebido e convicção por persona.




Figura 1: Proporção de escolhas utilitaristas e deontológicas em função do enquadramento retórico de tom ($\chi^2 = 39.57$, $p < 0.001$).




Figura 2: Efeito da escala de utilidade (razão de vidas salvas por sacrifício) na probabilidade de escolha utilitarista.

Figura 3: Forest Plot de Tamanho de Efeito dos Fatores Modifi (Odds Ratio ajustado e Intervalos de Confiança de 95%




Figura 3: Forest plot de Razão de Chances (Odds Ratio) e IC de 95% para os fatores modificadores na adoção de condutas utilitaristas.

Figura 4: Matriz de Tensão Moral Percebida por Domínio e Tom (Intensidade de Conflito Ético na Tomada de Decisão do LLM)




Figura 4: Matriz de calor da tensão moral percebida (escore de 1 a 5) discriminada por domínio de aplicação e persona.

5. Discussão Aprofundada dos Fatores Modificadores

5.1. A Frieza Algorítmica da Persona Pragmática vs. A Inibição Empática:

O achado de que o tom *Pragmático* eleva as decisões utilitaristas para seu ápice estatístico demonstra que a instrução orientada a custos-benefícios e eficiência operacional neutraliza ativamente o peso normativo dos direitos individuais. Em contrapartida, sob o tom *Empático*, a saliência linguística do sofrimento humano individual e a irreparabilidade do luto acionam heurísticas de não-maleficência, duplicando a taxa de rejeição deontológica do sacrifício. Isso comprova que a neutralidade moral de um LLM é altamente volátil e dependente da camada de persona injetada no system prompt.

5.2. O Efeito Escalar da Razão de Vidas Condicionado à Modalidade de Ação:

A análise da razão de vidas demonstrou uma progressão moderada de 37.5% de decisões utilitaristas na razão 1:2 para 50.0% nas razões 1:5 e 1:20 ($\chi^2 = 1.68$, $p = 0.4321$). Embora a tendência de aumento de adesão consequencialista com o aumento do saldo de vidas salvas seja observável, o teste qui-quadrado não atingiu significância estatística a 5% de forma isolada. Esse achado é teoricamente revelador: indica que, nos modelos de linguagem modernos, a simples ampliação numérica das vidas salvas não é suficiente por si só para revogar imperativos deontológicos quando o dano é instrumental ativo, demonstrando uma robustez principiológica surpreendente na rejeição da instrumentalização humana.

5.3. A Validação da Doutrina do Duplo Efeito (Ação Instrumental vs. Colateral):

A Doutrina do Duplo Efeito se confirmou como um dos fatores mais potentes do experimento (Odds Ratio = 12.25, $p = 1.7392e-09$). Quando o sacrifício da vítima inocente é o meio físico direto e instrumental para alcançar a salvação alheia (e.g. atirar um corpo como trava mecânica ou forjar incriminação deliberada), o modelo resiste veementemente à execução da ação, justificando sua recusa na 'proibição de instrumentalizar vidas humanas'. Quando o mesmo desfecho fatal ocorre como efeito colateral inevitável de um desvio de perigo, a tolerância utilitarista se expande vertiginosamente.

6. Implicações para Engenharia de Alinhamento e Governança

Estes resultados trazem implicações práticas profundas para a engenharia de software e a conformidade regulatória de sistemas autônomos:

- **Vulnerabilidade a 'Moral Framing Hacking':** Agentes de IA autônomos atuando em finanças, justiça ou segurança pública podem ser induzidos a violar direitos fundamentais ou quebrar tratados éticos simplesmente pela imposição de um enquadramento semântico pragmático/operacional. Engenheiros de segurança devem criar salvaguardas (guardrails) constitucionais imunes à modulação de tom.
- **Regulamentação de Veículos Autônomos e Robótica Crítica:** Os achados corroboram a necessidade de explicitar nos códigos de ética de tráfego (como as diretrizes da Comissão de Ética da Alemanha para Condução Automatizada) que sistemas algorítmicos não podem tomar decisões arbitrárias de discriminação de vidas baseadas unicamente em contabilidade utilitária ad-hoc.
- **Transparência em Triagem Clínica Computacional:** Softwares de alocação de leitos e órgãos não devem operar com 'caixas-pretas' de aprendizado por reforço que ocultem trade-offs consequencialistas dos médicos assistentes.

7. Limitações Metodológicas e Trabalhos Futuros

Reconhecem-se como limitações do presente estudo: (1) O viés decorrente do processo de RLHF (Reinforcement Learning from Human Feedback), onde os alinhadores humanos das big techs tendem a recompensar respostas utilitaristas percebidas como 'racionais e objetivas'; (2) A natureza estilizada de dilemas do tipo bonde (trolley problems), que abstraem a incerteza probabilística e a incompletude informativa do mundo real; (3) A exploração focada primariamente na família Gemini em nuvem, recomendando-se para trabalhos futuros a replicação comparativa contra modelos abertos locais (ex: Llama-3, Gemma-2, Mistral).

8. Conclusão

O presente estudo planejou e executou com sucesso um experimento fatorial estatisticamente rigoroso baseado no repositório DilemaLLM, quantificando com precisão matemática a tensão entre ética utilitarista e deontológica em modelos de linguagem avançados. Constatou-se que o modelo em nível basal agregado preserva uma distribuição equilibrada (45.8% utilitarista vs. 54.2% deontológica, $p = 0.4114$), refutando a premissa de um viés utilitarista cego incondicional. Em contrapartida, comprovou-se que fatores modificadores como a persona de resposta ($\chi^2 = 39.57$, $p < 0.001$) e a Doutrina do Duplo Efeito ($OR = 12.25$, $p < 0.001$) exercem poder determinante sobre a decisão moral da IA. O framework desenvolvido consolida uma metodologia reproduzível e extensível para benchmarking contínuo de segurança e governança ética de agentes inteligentes.

9. Referências Bibliográficas

- AWAD, E. et al. The Moral Machine experiment. **Nature**, v. 563, n. 7729, p. 59–64, 2018.
- BENTHAM, J. **An Introduction to the Principles of Morals and Legislation**. Londres: T. Payne and Son, 1789.
- BOSTROM, N. **Superintelligence: Paths, Dangers, Strategies**. Oxford: Oxford University Press, 2014.
- FOOT, P. The Problem of Abortion and the Doctrine of the Double Effect. **Oxford Review**, n. 5, p. 5–15, 1967.
- GREENE, J. D. et al. The neural bases of cognitive conflict and control in moral judgment. **Neuron**, v. 44, n. 2, p. 389–400, 2004.
- HENDRYCKS, D. et al. Aligning AI With Shared Human Values. In: **International Conference on Learning Representations (ICLR)**, 2021.
- KANT, I. **Grundlegung zur Metaphysik der Sitten** (Fundamentação da Metafísica dos Costumes). Riga: Johann Friedrich Hartknoch, 1785.
- MILL, J. S. **Utilitarianism**. Londres: Parker, Son, and Bourn, 1861.
- RUSSELL, S. **Human Compatible: Artificial Intelligence and the Problem of Control**. Nova York: Viking, 2019.
- THOMSON, J. J. Killing, Letting Die, and the Trolley Problem. **The Monist**, v. 59, n. 2, p. 204–217, 1976.

Apêndice Técnico: Reprodutibilidade e Schema Pydantic

A integridade dos dados foi garantida através do seguinte schema Pydantic tipado, executado no script `experimento_etico.py` do repositório DilemaLLM:

```
class DecisaoEtica(str, Enum):
    UTILITARISTA = "UTILITARISTA"
    DEONTOLOGICA = "DEONTOLOGICA"

class ResultadoEnsaio(BaseModel):
    decisao: DecisaoEtica
    justificativa_sintetica: str
    intensidade_conflito: int = Field(ge=1, le=5)
    grau_certeza: int = Field(ge=1, le=5)
    principio_predominante: str
```